

GOAI 2026 · AI for Research 赛道 · 材料方向 · 进阶路线 C (合成路线与工艺设计)

SAGE-Mat

面向无机材料合成调研与合成规划的证据约束多智能体系统

开源实现：GoAI Research —— 9 个 agent 技能 · 4 个 MCP server · 账本驱动的质量回环

一行主题进去，**可核验的综述、证据链与候选合成路线**出来

高京（上海交通大学）· 吕丁阳（中国科学院大学）· 李雨峰（上海交通大学）

Harness：Codex CLI 0.146.1 · 模型 gpt-5.6-sol · reasoning xhigh

github.com/asimfish/goai_research · tag goai-final-2026-09-03 · MIT

51 / 51

正式报告文献三轴核验全部通过

100 条

结论逐条追溯到 DOI 与原文

2,558

条留出反应上重算前驱体预测基准

23 页

纯主题冷启动生成的正式综述

2026-09 · 复赛作品说明

合成条件散落在文献里，“哪些能迁移”才是要回答的科学问题

对只有单篇报道的化合物，研究者需要知道文献能限定什么、哪些近邻条件可以迁移、哪些迁移**不成立**，以及下一步做什么实验**最有发现价值**。

案例 A · Ba₅Y₁₂Zn[O(SiO₄)]₈ (BYZSO)

2024 年首次报道的非中心对称硅酸盐；
公开文献仅 **1 篇** 直接合成报道，未给出可复现的
投料比、温程与冷却程序；Ba-Y-Si-O、
Ba-Zn-Si-O、Y-Si-O 近邻体系证据丰富。

文献稀缺 · 近邻丰富

案例 B · LLZO 石榴石固态电解质 (初赛承诺)

低温致密化、两步烧结、冷烧结、超快烧结
各有先例，却缺少**跨掺杂体系可比**的统一
工艺图景；温度、气氛与致密度只有在实验
语境一致时才能比较。

文献丰富 · 条件不可比

三个难点

 检索混入综述与参考文献列表

召回率与阅读成本相互牵制

 “未检出”不等于“未研究”


别名、缩写与语料覆盖会制造假空白

 数值只在语境一致时可比

误读升温节点或淬火温度会产生假规律

系统把“生成像论文的结论”改为“保存证据与判定过程”

三层分离：认知交给宿主模型，确定性工作进 MCP server，“完成”由代码判定。



🧠 认知层 · 9 个 agent 技能

编排 / 检索 / 风格库 / 引用核验 / 分类法与写作 / 图纸 ×2 / 想法与方案 / 对抗审稿；纯 Markdown，由 Codex 宿主执行，即提交的 Prompt 全集。

📋 确定性层 · 4 个 MCP server

litsearch（在线五源 + 本地库）· refcheck（三轴核验）· figure（figspec → SVG + draw.io）· retro（两阶段前驱体预测）；25 个工具全部可离线测试。

🔄 控制层 · 账本驱动的回环

9 个出口闸门记录在 ledger.json；check-done 需全部落账、无 FAIL、审稿 PASS 带真实回执；
审稿人不改稿，执行者不自判。

图：发现 → 生产（并行）→ 质量回环。由系统自身的 figspec 渲染器生成，同源输出 SVG 与 draw.io。

九个出口闸门由代码判定完成，审与做分离

完成不是模型自报：check-done 只在九个闸门全部落账、无 FAIL、无 open blocker / major，且 review_pass 指向真实存在的审稿 trace 时才退出 0。



👤 人工停点：正式运行触发 4 次，同一主题续跑

- ① 范围草案自动确认 (裸主题、范围无实质歧义)
- ② 5 条作者名 MISMATCH 三轮未收敛 → 升级人工，采纳“删除这 5 条背景文献并继续”
- ③ 贡献结构确认：身份谱系 / 路线—变量—验证矩阵 / 迁移边界
- ④ 终审：0 blocker / 0 major / 0 minor，PASS 带回执落账

🔄 对抗审稿：审与做永远分离

- 全新上下文的独立 reviewer；先验证后批评 (指控引用造假前必须先跑 verify_entry)
- 三视角裁决：领域专家 / 方法严谨派 / 期刊编辑
- 结构化 issue 带 target 阶段，路由回属主返工，上游变更级联重置下游闸门
- 同一 issue 三轮未收敛升级人类；无回执的 PASS 被账本拒绝

RECIPE: 把无机逆合成重述为变长前驱体集合的排序问题

团队 NeurIPS 2026 投稿。Generator 先保证召回，再对**完整前驱体集合**直接排序；
以 MCP 工具 `predict_precursor_routes` 进入想法环节，输出只能是“模型候选、待实验验证”。

① Candidate Generator

formula-token Transformer 打分：
目标式 × 798 个前驱体，多标签 BCE

产物：Top-30 高召回候选池

② 化学硬过滤 + 变长枚举

非挥发元素 $\subseteq$ 目标元素 (pool ≤ 15) ;
枚举 2-5 元组合，不预设真实集合大小

产物：典型 4,928 个候选集合

③ Complete-Set Reranker

目标条件化集合 token + 374 维描述子，
listwise 排序 · 负样本间隔 · 覆盖监督

产物：Top-K 完整集合及分数

融入规则 (skill 层硬约束)

- 每条路线带 `chemical_route_verified=false`，正文只能写“模型候选，待实验验证”，不得表述为实验真值
- 返回 Stage-1 概率、Stage-2 分数、候选池内概率、checkpoint SHA-256，供审稿人逐条核对
- 路线须经文献证据补全与 reviewer 复核后才能进入方案

正式报告中的三次调用 (Top-1 · 候选池内概率)

Zn 目标 → ZnO + Y2O3 + SiO2 + BaCO3

常规氧化物 / 碳酸盐原料集合 · **0.594**

Mg 类比 → MgO + Y2O3 + BaCO3 + SiO2 · **0.522**

Co 类比 → Co3O4 + Y2O3 + BaCO3 + SiO2 · **0.298**

前三名反映 Co 氧化态不确定性，而非三条等价处方

纯主题冷启动：51 篇文献全部核验、100 条结论全部可追溯

唯一输入是一行主题“Ba₅Y₁₂Zn[O(SiO₄)]₈ 及其结构相近化合物的合成条件”；系统在 4 个人工停点续跑后交出 20 页综述，再按材料专家 8 条意见修订为 **23 页正式稿**。

51 / 51

文献三轴核验全部 PASS

219


次引用，整合率 100%

3 张

figspec 同源可编辑图

0

两轮对抗审稿的终审 issue 数



运行事实（全部留痕于 submission/goai_final/run）

- 顶层编排器 5 次调用（首轮 + 4 次续跑），29 批 / 40 个子任务
- 63 条候选 → 51 篇入库；5 条作者名 MISMATCH 经人工停点删除
- 两轮对抗审稿：首轮 7 项 issue 路由返工，第二轮 0 / 0 / 0
- 正式报告调用前驱体预测 3 次（Zn / Mg / Co 目标）
- 专家反馈修订：正规论文语言、同类体系单独成节、前人结论汇总、方向落到工艺与前驱体、相图讨论、学术排版图、去除工程术语

左图：正式报告研究路线图（第三轮学术化重绘）

目标相只有一篇直接报道；组成坐标比单一温度更能解释成相

系统给出的不是配方，而是文献证据限定的可迁移范围与四类可检验的实验方向。

既有文献能够确认什么

- 1 公开证据只能确认“开放体系高温溶液法 + 单晶 X 射线衍射鉴定”，不足以给出经验证的目标相复现配方。
- 2 无 Zn 谱系提供三类可比路线：MoO₃ 助熔（Pt 坩埚、1150 °C、2 K/h）、x:26:16 固相陶瓷（1300 / 1600 °C）、5:13:8 粉体相场筛查（1273 / 1573 K）；具体数值不得无条件迁移。
- 3 “获得单晶”不等于“建立批量相纯窗口”；
局部相图是连接复现与科学发现的核心实验。

条件单元格逐字段区分“可支持 / 不可支持”，36 条带原文页、节定位
(evidence/notes/condition_source_trace.md)

四个值得探索的方向（各配工艺与前驱体）

- ① 目标组成附近的局部相图
固相成相组成系列 + 定量 PXRD / Rietveld 相分数
- ② Zn-Y-氧计量耦合
名义 / 实际化学计量对照，EDS / EPMA 与结构模型互证
- ③ 固相成相与高温溶液长晶并行
单晶确认结构模型，批量样品测定目标相比比例
- ④ Mg / Co 类比与模型前驱体
位点 / 价态探针；Co 需联测氧分压与烧后价态

模型候选（待实验验证） Zn: ZnO + Y₂O₃ + SiO₂ + BaCO₃

Mg: MgO + Y₂O₃ + BaCO₃ + SiO₂

Co: Co₃O₄ + Y₂O₃ + BaCO₃ + SiO₂

LLZO 诊断轮跑通端到端，并暴露、修复了 11 类集成失效模式

初赛承诺的主题：46 篇文献六个子主题覆盖、46 / 46 核验通过、10 页综述；

模型 Top-1 与文献一致，Top-2 起出现可疑命名，因此保留“模型生成—规范化—文献复核—审稿”闸门。

46

篇文献入库，修正 3 条元数据后 46 / 46 PASS

21 · 49

个 Agent 任务 · 次 MCP 调用 (stdio 协议)

10 页

A4 综述 PDF，46 篇全部整合

Top-1 $\text{ZrO}_2 + \text{La}_2\text{O}_3 + \text{Li}_2\text{CO}_3$ 与文献一致

Top-2-5 LiHO 、 $\text{La}(\text{HO})_3$ 等 → 化学路线未验证

⚠ 11 类失效模式，全部留痕并修复


- MCP 审批配置 (无人值守自动拒绝)
- Agent 工作目录错误
- 并行写文献库竞争
- `exit=0` 假成功 / 旧产物假成功
- 上下文与 token 膨胀
- 上游 API 限流
- 图片 lint 假绿
- retro 字段不兼容
- 测试输出契约漂移
- 同模型审稿独立性不足
- check-done 单闸门即宣告完成
(冷启动首次尝试暴露，PR #17 机械化修复)

修复说明: docs/FAILURE_MODE_FIXES.md · LLZO_AGENT_INTEGRATION_AUDIT.md

替代材料分析 $\text{Li}_6\text{PS}_5\text{Cl}$ · Li_3YCl_6 · LATP 的模型 Top-1 路线均通过文献复核，分别对应高电导冷压、高电压正极侧、低成本空气操作三种场景。

留出测试集重算：Combo@1 71.81，比 Retrieval-Retro 高 11.4 点

用与 MCP 工具**完全相同的推理代码**在 2,558 条留出反应上重算，结果与 checkpoint 自带汇总**逐位一致**，并落在论文三种子均值的误差区间内。



Retro 测试集 2,558 条，精确集合命中率 %，全分母；top_m 30 · pool 15 · 集合 2-5 元

读数与对照

Stage 1 Top-20 覆盖

95.78 (基线 92.96)

论文三种子均值

$71.70 \pm 0.10 \cdot 84.52 \pm 1.48$

$89.82 \pm 1.74 \cdot 77.43 \pm 0.69$

同枚举 product 对照

Combo@1 11.65 · MRR 23.24

→ 增益来自**学习到的集合级排序**，而非候选枚举或过滤本身

eval_retro_benchmark.py · GPU 19 分钟

metrics/retro_benchmark.json

逐目标名次: ...per_target.jsonl

每条结论可追溯：代码版本、配置、数据、轨迹、结果文件

报告中 **100 条结论**、**3 张图**、**每条前驱体预测**都能沿同一条链回到提交包中的具体文件。



示例 · claim_evidence.jsonl 第 C012 条

“该文采用开放体系高温溶液法，并以单晶 X 射线衍射鉴定晶体。”

引用键 ababaikeri2024ba5y12zn · DOI 10.1039/D3NJ04480G · refcheck 三轴 **PASS** · 支持强度 strong

写作任务 write_identity_evidence (tasks_write_sections.tsv) → parallel/20260901_003133_1289042/write_identity_evidence.jsonl

→ sections/01_phase_identity.tex → 正式 PDF 第 1 章“目标相出处”

运行统计

40 个子任务 / 29 批 · 7,084 万输入 token
224 次工具函数调用 · 205 次网页搜索
134 条服务端审计的全文库与预测调用

Agent 轨迹（分目录）

构筑：原生 rollout 43 轮 + 网关 3,399 条
运行：40 个子任务 JSONL + 51 个原生会话
Harness：Codex CLI 0.146.1 · gpt-5.6-sol · xhigh

数据边界

私有全文库（约 3,760 万篇）不公开
被引 51 篇中 21 篇全文进公开知识库
其余 30 篇以 DOI + 官方链接提供

干净环境一键冒烟 1-2 分钟；核心流程以闸门一致为复现判据

确定性部分（基准、渲染、闸门）**可逐位复现**；LLM 部分不可逐字复现，以 check-done 退出 0、CITATION_AUDIT 全部 PASS、bib_guard 整合率 $\geq 90\%$ 作为核心流程的复现判据。

```
$ bash install.sh --retro
$ bash scripts/smoke_test.sh --with-retro
OK python 3.10 · 4 MCP servers importable
OK 56 passed (offline tests, no network)
OK lookup_local_doi -> public corpus package
OK 100 claims / 219 citation calls / 51 verified keys
OK figspec -> svg + drawio
SMOKE TEST PASSED

$ .venv-retro/bin/python tools/eval_retro_benchmark.py
Combo@1 71.81 · Combo@20 89.21 · MRR 77.48 (bit-identical)

$ bash scripts/reproduce_core.sh --topic "...
Codex CLI 0.146.1 · gpt-5.6-sol · reasoning xhigh
```

冒烟测试 1-2 分钟无网络、无 LLM；基准重算 GPU 19 分钟；核心流程需 Codex 登录与网络

⚠ 已知限制（如实披露）

- 1 目标相仅 1 篇直接报道、无独立复现；
报告不给出“已验证配方”，只给可迁移范围与实验方向
- 2 公开知识库只含被引文献中 21 / 51 篇全文，
其余 30 篇以 DOI 提供；在线检索与核验不受影响
- 3 终审为同家族模型的冷启动复审（provisional）；
跨模型审稿已支持，本次未启用
- 4 正式 PDF 含专家反馈驱动的修订，全部轨迹留痕；
LLM 步骤不可逐字复现，复现判据见上

7 组运行全部留痕；正式结果取最后一个同时通过全部机械闸门（引用、稿件、术语、终审）的版本，不在多次运行间“挑最好的一次”。

MIT 开源、tag 固定；下一步是跨模型审稿与实验验证

这套系统真正改变的，是把“该不该相信这条结论”
变成一个可以点开 DOI 与原文段落回答的问题

文献稀缺（BYZSO）与文献丰富但不可比（LLZO）两种情形下，都产出了可逐条核对的结论与可检验的实验建议

🔓 开源情况

github.com/asimfish/goai_research

MIT · tag goai-final-2026-09-03

提交全部 Prompt、配置、依赖版本、
模型 checkpoint、构筑与运行轨迹、
证据包与指标代码

仓库在提交前设为公开

🔗 可复用的部分

- 任意主题的综述回环（账本 + 闸门）
- 引用零信任核验（三轴、作者顺序）
- figspec 可编辑图纸：SVG + draw.io
- 无机前驱体预测 MCP 工具（RECIPE）
- 精简知识库导出与结论—证据映射

🔮 下一步

- 接入跨模型审稿（Claude Code），
替代同家族复审
- 对四个方向开展合成实验，
把实验结果回写为证据
- 扩展条件预测器（温度 / 气氛 /
助熔剂），与前驱体预测联用

高京（上海交通大学）· 吕丁阳（中国科学院大学）· 李雨峰（上海交通大学）· SafeLab ICML 2026 · AI4Science 黑客松沪京双站三等奖